

Segmentação de Bancos de Areia no Rio Tapajós

Imagens Sentinel-2 com U-Net

Gabriel Alves
Giann Correa

Instituto Nacional de Pesquisas Espaciais

2026

Problema


Pergunta do projeto

Como identificar automaticamente bancos de areia em imagens multiespectrais do Rio Tapajós?

- Bancos de areia ocupam poucos pixels na cena.
- Margens, ilhas, solo exposto e nuvens podem ter aparência parecida.
- O problema é uma segmentação binária: banco de areia ou fundo.

Desafio principal

Reduzir falsos positivos sem deixar de detectar bancos pequenos.



Fonte:
recortes e resultados gerados no projeto.

Dados utilizados

Entrada do modelo


Recortes Sentinel-2 com 6 bandas:

- B2, B3, B4;
- B8, B11, B12.

Também foram calculados dois índices no *Dataset*:

$$NDWI = \frac{B3 - B8}{B3 + B8}$$

$$MNDWI = \frac{B3 - B11}{B3 + B11}$$



Fonte: recortes e resultados gerados no projeto.


Construção do ground truth

Fluxo de anotação

- 1 Triagem manual das cenas.
- 2 Geração de pré-máscaras por índices espectrais.
- 3 Correção manual no QGIS.
- 4 Rasterização final da máscara.

Cada máscara tem:

- 0: fundo;
- 255: banco de areia.



Fonte: recortes e resultados gerados no projeto.

Após a revisão

Item	Qtd.
Cenas avaliadas na triagem	2.396
Positivas usadas	50
Negativas usadas	150
Total usado na validação cruzada	200

Proporção

1 positiva : 3 negativas


Por que usar negativas?

As negativas ensinam o modelo a rejeitar alvos parecidos com areia.

Exemplos de negativos importantes:

- água sem banco;
- margem clara;
- ilha vegetada;
- nuvem ou solo exposto.

Pipeline do método



Entrada

Tensor com 8 canais: 6 bandas + NDWI e MNDWI.

Saída

Um mapa binário indicando os pixels de banco de areia.

Modelo e treinamento

Arquitetura

- U-Net para segmentação binária.
- Encoder ResNet com *transfer learning*.
- *Skip connections* para recuperar detalhes espaciais.
- Saída com 1 canal e *sigmoid* na inferência.

Pré-processamento

- Tratamento de NaN e Inf.
- Normalização das bandas.
- Padding/crop para 144×144 .

Loss e busca

- Focal Loss + Dice Loss no experimento principal.
- Busca de hiperparâmetros com Optuna.
- Escolha de threshold pela validação.

Checkpoint final


O notebook salva o modelo final em
`/kaggle/working/unet_modelo_final.pt`.

Por que usar U-Net?

Ideia central

A U-Net recebe a imagem multiespectral e devolve uma máscara com a mesma estrutura espacial.

- O encoder resume padrões espectrais e espaciais.
- O decoder reconstrói a segmentação pixel a pixel.
- As conexões laterais preservam bordas e objetos pequenos.



Motivo da escolha

O alvo é pequeno e irregular; por isso é importante manter informação espacial fina.

Transfer learning no encoder

Como foi usado

- O encoder da U-Net usa uma ResNet.
- A primeira camada é adaptada para receber 8 canais.
- O encoder aprende com uma taxa menor que o restante da rede.

Por que ajuda

Mesmo vindo de imagens naturais, o encoder já parte com filtros úteis para bordas, texturas e formas.

Cuidado

Mais canais nem sempre significa melhor resultado. Por isso, RGB, 6 bandas e 8 canais podem ser comparados depois.

Busca de hiperparâmetros com Optuna

Hiperparâmetro	Faixa buscada	Escala
Taxa de aprendizado	$5 \times 10^{-5} - 2 \times 10^{-3}$	log
Fator de lr do encoder	0,05 – 0,5	log
Weight decay	$10^{-6} - 5 \times 10^{-4}$	log
Encoder	resnet18 / resnet34	–
Batch size	4 / 8 / 16	–
Peso da Dice na loss	0,3 – 1,5	linear
α (Focal Loss)	0,25 – 0,9	linear
γ (Focal Loss)	0,5 – 3,0	linear

Estratégia de busca

- Amostrador TPE.
- *Pruning* por mediana.
- 15 tentativas por fold externo.
- 12 épocas por tentativa.

Divisão em patches

Estratégia

As cenas são convertidas em recortes de tamanho fixo antes do treinamento.

- Tamanho usado: 144×144 pixels.
- Padding/crop mantém todas as entradas com o mesmo tamanho.
- A divisão em patches permite usar cenas maiores no futuro.

Evitar vazamento de dados

A separação treino/teste é feita por cena antes da divisão em patches.

Assim, patches da mesma imagem não aparecem ao mesmo tempo no treino e no teste.


Observação deste conjunto

Como muitos recortes já são menores que 144×144 , o tiling gerou praticamente um patch por cena.

Validação cruzada aninhada

- 5 folds externos estimam o desempenho fora da amostra.
- Em cada fold externo, há um split interno para busca com Optuna.
- O threshold é escolhido na validação interna.
- O teste externo fica reservado para medir o fold.

Depois da avaliação, um modelo final é treinado com todas as cenas e salvo em checkpoint.



Modelo final e checkpoint

Após a validação

- Os hiperparâmetros dos folds são resumidos.
- O modelo final usa todas as 200 cenas.
- O arquivo final guarda pesos, hiperparâmetros, threshold e o desempenho estimado pela validação.

Arquivo salvo

`/kaggle/working/unet_modelo_final.pt`

Métricas de segmentação

- **Dice** = $\frac{2 TP}{2 TP + FP + FN}$
Sobreposição entre a máscara prevista e a real.
- **Precision** = $\frac{TP}{TP + FP}$
Dos pixels previstos como banco, quantos eram de fato.
- **Recall** = $\frac{TP}{TP + FN}$
Dos bancos de areia reais, quantos foram detectados.
- **F1-score** = $\frac{2 P \cdot R}{P + R}$
Resume o equilíbrio entre Precision (P) e Recall (R).

TP: verdadeiro positivo **FP**: falso positivo **FN**: falso negativo

Dice = F1-score

Em segmentação binária por pixel, o F1-score se reescreve como $F_1 = \frac{2 TP}{2 TP + FP + FN}$, a mesma expressão do Dice. Portanto, neste trabalho:

$$F_1 = \text{Dice}$$

Por que destacar o Dice?


Bancos de areia ocupam poucos pixels por cena, e o IoU pune fortemente erros pequenos de borda (denominador pequeno). O Dice é mais tolerante: $\text{Dice} = \frac{2 \text{IoU}}{1 + \text{IoU}}$ — por isso é mais usado para avaliar segmentação de objetos pequenos [3].

Resultados obtidos até o momento

Métricas out-of-fold

Métrica	Valor
Dice	0,335
Precision	0,3006
Recall	0,3783

Resultado ainda baixo, mas útil como primeira baseline.



O que os resultados indicam

- A U-Net consegue aprender algum sinal da classe banco.
- A sobreposição ainda é baixa.
- Há dificuldade para separar banco de areia de alvos parecidos.


Problema observado

A precision baixa indica falsos positivos.

Em termos práticos:

- algumas regiões previstas como banco não são banco;
- margem, ilha e solo exposto podem confundir o modelo;
- o dataset positivo ainda é pequeno.

Exemplo de predição



A predição acompanha parte da máscara manual, mas o resultado varia conforme o fold e o threshold.

O que limita o desempenho

Limitações dos dados

- Apenas 50 cenas positivas.
- Bancos ocupam poucos pixels.
- Algumas máscaras são muito pequenas.
- Há classes visualmente parecidas com areia.

Limitações do treinamento

- Poucas amostras por fold.
- Thresholds variaram entre folds.
- O tiling não aumentou o dataset quando a cena já era menor que 144.
- A busca do Optuna ainda é sensível ao conjunto pequeno.

Próximos passos

Aumentar o dataset

Usar o rio Araguaia e Madeira no período de outubro.



Vista aérea do Rio Araguaia. Fonte: Guia Geográfico.

Síntese

Foi construído um pipeline completo para segmentação de bancos de areia: triagem, máscaras manuais, dataset positivo/negativo, U-Net com transfer learning, Optuna e validação cruzada aninhada.

- O modelo já produz uma baseline mensurável.
- O desempenho ainda é limitado.
- O maior desafio é reduzir falsos positivos.

Obrigado!

Referências principais

-  Ronneberger, O.; Fischer, P.; Brox, T. *U-Net: Convolutional Networks for Biomedical Image Segmentation*. MICCAI, 2015.
-  Lin, T.-Y. et al. *Focal Loss for Dense Object Detection*. ICCV, 2017.
-  Milletari, F.; Navab, N.; Ahmadi, S.-A. *V-Net: Fully Convolutional Neural Networks for Volumetric Medical Image Segmentation*. 3DV, 2016.
-  ESA. *Sentinel-2 User Handbook*. European Space Agency.

Segmentação de Bancos de Areia no Rio Tapajós

Imagens Sentinel-2 com U-Net

Gabriel Alves
Giann Correa

Instituto Nacional de Pesquisas Espaciais

2026